

Raport

Wprowadzenie do Sztucznej Inteligencji - Ćwiczenie 1.

Zagadnienie przeszukiwania przestrzeni i podstawowe podejście do niego

Autor: Aleksandra Jamróz, nr albumu: 310 708

Treść zadania: Implementacja metody spadku gradientu i metody Newtona szukania minimum funkcji na podstawie otrzymanego pseudokodu. Podana funkcja: funkcja Bootha postaci: $f(x,y) = (x + 2*y - 7)^2 + (2*x + y - 5)$, $-5 \leq x, y \leq 5$.

Pseudokody:

Steepest Gradient Descent

```
x <- x_0
while !stop
d <- grad_q(x)
x <- x+B_t * d
```

Newton Method

```
x <- x_0
while !stop
d <- inv_hess_q(x) * grad_q(x)
x <- x+B_t * d
inv_hess - odwrotność hesjanu
grad - gradient
```

Aby móc swobodnie liczyć kolejne wartości dla funkcji Bootha, policzyłam na początku wzór na gradient funkcji w dowolnym punkcie, pochodne zarówno pojedyncze jak i podwójne po x i y , macierz Hessego oraz jej odwrotność. Otrzymane wartości:

Pochodna po x : $10*x + 8*y - 34$;

Pochodna po y : $8*x + 10*y - 38$;

Gradient to wektor składający się z pochodnej po x i y : [pochodna po x , pochodna po y];

Macierz Hessego: $\begin{bmatrix} 10 & 8 \\ 8 & 10 \end{bmatrix}$;

Odwrotna macierz: $\begin{bmatrix} 5/18 & -4/18 \\ -4/18 & 5/18 \end{bmatrix}$;


Do rozwiązania zadania wykorzystałam następujące biblioteki:

- Numpy, matplotlib – do generowania wykresów funkcji
- Random – do generowania losowych punktów do obserwacji
- Timeit – do pomiaru czasu wykonania funkcji


Po zaimplementowaniu algorytmów przeprowadziłam serię prób wykorzystując różne wartości kroku oraz współrzędnych punktów. Na tej podstawie można opisać pewne obserwacje.

Wraz ze zmniejszeniem wartości kroku, czas wykonania funkcji wydłuża się. Wynika to z zwielokrotnienia potrzebnej liczby iteracji. W przypadku metody gradientu wartość kroku przekraczająca 0,06 powodowała „przeskakiwanie” funkcji nad optimum dając efekt „rozhuśtania” wykresu. W przypadku metody Newtona taka sytuacja miała miejsce po przekroczeniu wartości 1. Przy odpowiednim doborze parametru kroku, różnica w czasie wykonania funkcji gradientu i funkcji Newtona okazuje się minimalna, przy czym metoda Newtona daje najlepsze wyniki kiedy wartość kroku oscyluje w pobliżu 1, a metoda gradientu – 0,1.


Wykresy metody gradientu dla punktu $x = 4, y = 4$ i różnych wartości kroku:




Rysunek 1. Wykres gradientu



Rysunek 2. Wykres gradientu




Rysunek 3. Wykres gradientu

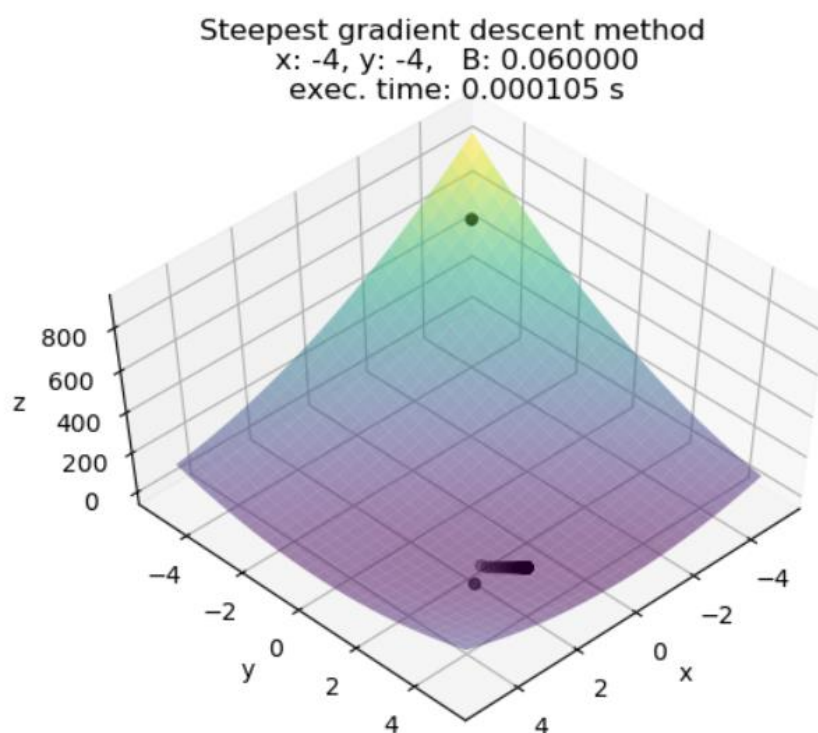


Rysunek 4. Wykres gradientu

Wykresy metody gradientu dla punktu $x = -4$, $y = -4$ i różnych wartości kroku:




Rysunek 5. Wykres gradientu




Rysunek 6. Wykres gradientu

Steepest gradient descent method
x: -4, y: -4, B: 0.010000
exec. time: 0.000679 s




Rysunek 7. Wykres gradientu

Steepest gradient descent method
x: -4, y: -4, B: 0.001000
exec. time: 0.008883 s

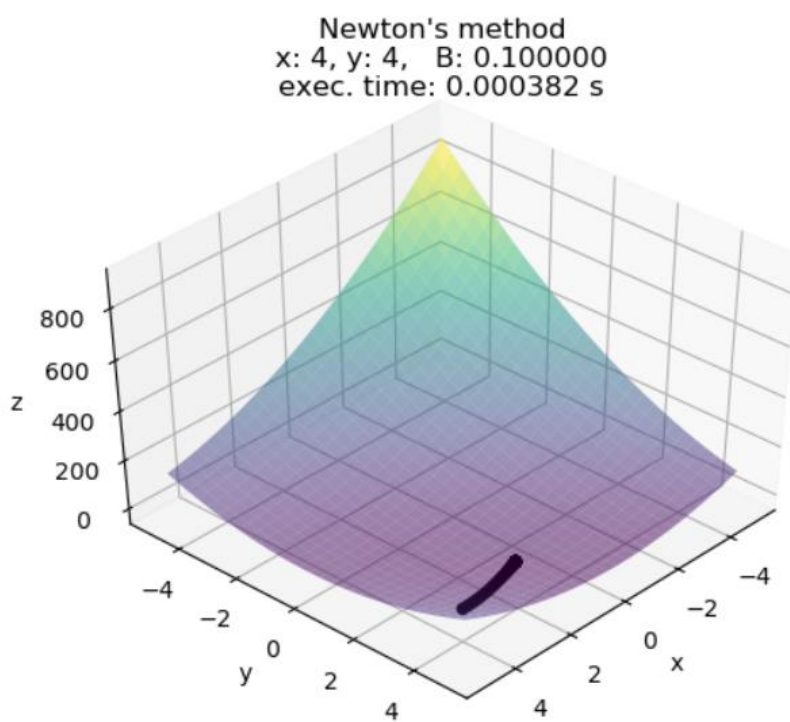


Rysunek 8. Wykres gradientu


Wykresy metody Newtona dla punktu $x = 4, y = 4$ i różnych wartości kroku:



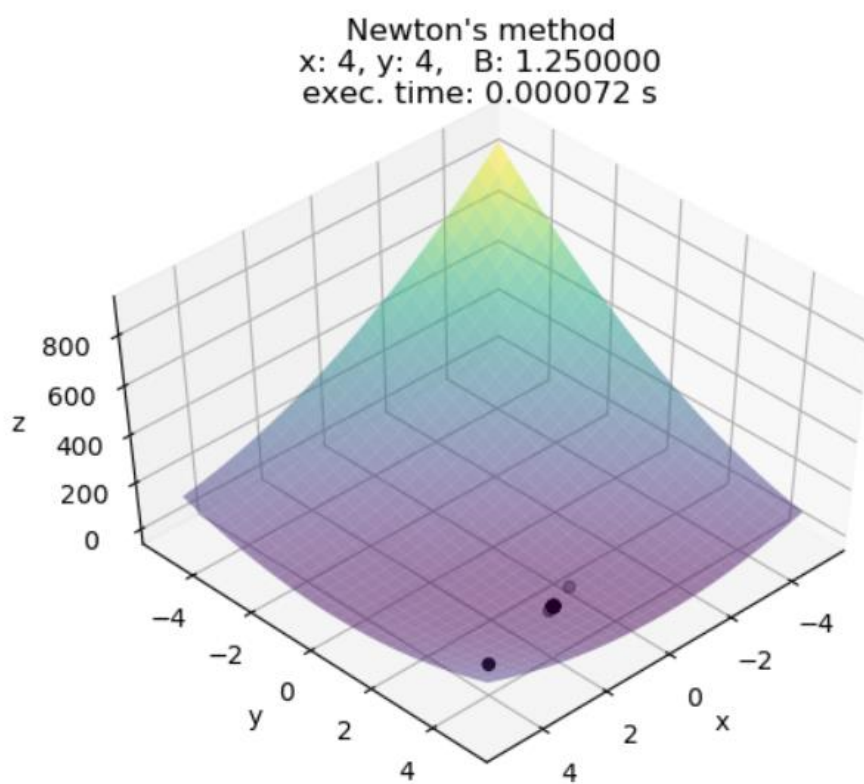
Rysunek 9. Wykres metody Newtona



Rysunek 10. Wykres metody Newtona




Rysunek 11. Wykres metody Newtona




Rysunek 12. Wykres metody Newtona

Wykresy metody Newtona dla punktu $x = -4$, $y = -4$ i różnych wartości kroku:




Rysunek 13. Wykres metody Newtona




Rysunek 14. Wykres metody Newtona

Newton's method
x: -4, y: -4, B: 0.500000
exec. time: 0.000100 s



Rysunek 15. Wykres metody Newtona

Newton's method
x: -4, y: -4, B: 0.100000
exec. time: 0.000192 s



Rysunek 16. Wykres metody Newtona